

Теорема Байеса – 1: спам-фильтр

Для получения зачёта по спецкурсу нужно решить все или почти все задачи из двух листочков. Первый листочек посвящен наивному байесовскому классификатору, второй будет посвящен условной энтропии. Рассказывать решения задач можно мне в любое время.

Задача 1. Имеются две монеты: честная и нечестная. У честной монеты вероятность выпадения решки равна 0.5. У нечестной — 0.1. Сначала мы равновероятно выбираем одну из двух монет, после чего кидаем её. Пусть при этом броске выпала решка. Какова вероятность того, что мы бросали честную монету?

Задача 2. Пусть A и B — два события на некотором вероятностном пространстве Ω . Пусть $P(B) > 0$. Тогда события A и B независимы тогда и только тогда, когда $P(A | B) = P(A)$.

Задача 3. Бросают два игральных кубика: белый и красный. Посчитайте условную вероятность того, что на каждом кубике выпало не менее 3 очков, при условии, что сумма выпавших очков равна 7.

Задача 4. Ваша задача — построить классификатор, который будет отличать английские слова от не-английских. Слова порождаются источником со следующими вероятностями появления слов:

элемент в Ω	слово	английское слово?	вероятность
1	ozb	нет	$2/7$
2	uzu	нет	$2/7$
3	zoo	да	$3/14$
4	bun	да	$3/14$

(а) Вычислите вероятности классов и условные вероятности для multinomial-классификатора¹, который использует в качестве признаков буквы b, n, o, u и z. Исходите из того, что выборка, на которой будет обучаться классификатор, будет идеально отражать вероятности источника слов. Также примите в качестве предположения, что позиция буквы в слове не влияет на его английскость. Используйте сглаживание, при котором вычисленные нулевые вероятности заменяются вероятностью 0.01, а ненулевые вероятности не изменяются. (При этом может оказаться, что $P(A) + P(\bar{A}) > 1$. С математической точки зрения это абсурдно, но при построении классификатора на это можно закрыть глаза.)

(б) Считает ли классификатор слова zoo, buzz, noob английскими?

(в) Пусть теперь классификатор строится так, что признаком является не буква, а пара (буква, позиция). К какому классу новый классификатор относит слово zoo? Вам нужно посчитать не все условные вероятности, а только те, которые влияют на классификацию слова zoo.

¹Multinomial-классификатор — это классификатор, который учитывает не только наличие/отсутствие признака, но и его количество. Например, если какая-то буква в слове встречается дважды, то это даст два множителя в итоговой формуле классификатора.